



重庆大学 / 计算机科学与技术 (卓越专业)

个人主页 [/ xiaowei.hua.cn](https://xiaowei.hua.cn)

本科在读 / 2023.09 - 2027.06

GitHub [/ Will-hxw](https://github.com/Will-hxw)

GPA 3.64/4.00 · 排名 35/309

邮箱 [/ xiaowei.huacqu@gmail.com](mailto:xiaowei.huacqu@gmail.com)

均分 88.69 · 综合测评年级前 3% · TOEFL 110

电话 / 微信 [/ 15730810078](https://t.me/15730810078)

实习经历

Tencent 腾讯 · TRS 推荐中台 / 推荐系统基础架构中心

向量数据库实习生 2025.06 - 2025.08

C++ / CUDA / Python / Go / Faiss / CUDA VMM

overview

参与推荐召回与 RAG 检索场景下的 GPU 向量检索基础设施建设, 围绕大 top-k selection、在线向量增删改、batch 调度与 CUDA VMM, 优化大规模向量召回的吞吐、尾延迟和动态更新效率, 并降低同卡多索引部署的 OOM 风险。

optimize

针对 Faiss GPU 大 top-k 检索中 selection 开销显著上升、原有 selection 接口难以直接处理分块距离结果的问题, 借鉴 Radik 的 radix selection 方法, 重构分块距离计算与 top-k selection 的衔接流程; 在 top-k=2048 场景下将 GPU 检索 QPS 提升约 13x, P99 延迟由秒级降至百毫秒级。

realtime

参与 Faiss GPU 在线向量增删改功能开发, 基于 CUDA VMM 对物理显存页进行按需映射与重映射, 并通过哈希表维护文档 ID 到向量槽位的映射, 减少删除与更新触发的数据压实及批量显存搬移, 将单条文档删除延迟由毫秒级降至微秒级。

scheduling

参与 GPU 检索在线请求聚合与调度组件设计, 使用无锁队列接收高并发请求, 由专用 batch 线程聚合零散单-query 请求, 并分发至检索线程池执行, 在控制排队延迟的同时增大有效 batch size, 提高 GPU 利用率与系统吞吐。

memory

参与 CUDA VMM 显存管理优化, 通过虚拟地址预留与物理页按需映射减少索引扩容中的重分配及数据搬移, 并以分块距离计算控制检索临时显存, 支持同卡部署多个索引实例, 降低扩容及数据更新阶段的 OOM 风险。

科研经历

跨视角几何一致性驱动的稀疏视角 3DGS

科研经历 2025.08 - 至今

PyTorch / CUDA / COLMAP / 3DGS 跨视角几何一致性 · 高斯置信度建模 · 增密与裁剪优化 · 新视角合成

problem

研究稀疏输入条件下 3DGS 的几何欠约束问题。原始 3DGS 主要依据视空间位置梯度触发 densification, 并根据尺度与不透明度执行 pruning, 缺少显式多视角几何约束, 难以区分真实结构欠表达与错误高斯形成的伪几何, 易产生漂浮高斯、边界破碎和纹理泄漏。

evidence

构建高斯级跨视角一致性评分, 为每个 Gaussian 统计可见视角数、相机基线分布、重投影误差、深度一致性及渲染贡献; 对各项证据归一化并加权融合, 得到几何支持度与置信度评分, 衡量其多视角观测可信度。

optimization

设计几何支持度与重建残差联合控制的高斯增密与裁剪策略: 对高支持度、高残差的高斯, 结合尺度选择 clone 或 split, 补充欠表达的场景结构; 对低支持度、高不一致性高斯执行 opacity decay 与 pruning; 在图像与深度边缘处约束高斯尺度和各向异性分裂方向, 减少跨边界纹理混合。

result

在 LLFF 3-view 及多组真实场景的不同输入视角数量设置下, 相较原始 3DGS, PSNR 平均提升约 0.6 dB、SSIM 提升约 0.015; 定性结果显示漂浮伪影、边界断裂和前景纹理泄漏减少, 同时抑制冗余高斯增长, 提升新视角渲染的稳定性。

项目经历

面向即时通信消息的 Agentic Retrieval 系统

GitHub [独立开发](#) 2026.02 - 至今

Agent / RAG / BGE-M3 / TypeScript / Node.js / MongoDB / React

problem

针对 IM 消息碎片化、表达口语化、话题交织及跨时段信息关联困难的问题, 构建 Agentic Retrieval 系统, 使用户围绕个性兴趣主题聚合有效信息、恢复事件上下文并追踪话题演化。

retrieval

设计查询规划—混合召回—相关性重排—上下文构建链路; 由 Agent 解析问题意图并生成时间、群组与话题约束, 基于 bge-m3 融合稠密与稀疏检索, 经 reranker 重排后按时间与话题聚合跨时段证据, 支持复杂约束查询与跨消息证据检索。

agent

将语义检索、结构化筛选、话题追踪和摘要生成封装为 Agent 工具, 引入证据充分性判定与 corrective retrieval; 在证据不足或冲突时自动改写查询并迭代检索, 生成附原始消息定位的回答总结。

system

设计消息—事件—主题三级知识组织与增量更新机制, 配合任务编排完成消息同步、向量索引更新和周期性事件与主题摘要合成, 实现跨时段问答、话题演化追踪及可追溯摘要生成。

🏆 学科竞赛与荣誉

算法 · 数学 · 综合

- 2025 年 ACM-ICPC 国际大学生程序设计竞赛 银牌
- 2026 年 团体程序设计天梯赛 个人三等奖
- 2025 年 百度之星程序设计大赛 银奖
- 2021 年 高中数学联赛 江西省一等奖
- 2023 年 全国大学生数学竞赛 重庆赛区一等奖
- 2025 年 国家励志奖学金
- 2026 年 重庆市创新能力优胜个人
- 校级甲等奖学金 3 次 (综合评测年级前 3%)

🔧 技术能力与研究兴趣

🔧 技术能力

数学与 Coding · 专业基础 · 科研能力 · 工程能力

- **数学与 Coding**: 具备手搓算法、复杂代码调试、论文公式推导与实验验证能力; 获 ICPC 银牌及高中数学联赛省一等奖。
- **专业基础**: 熟悉 C++ / Python / TypeScript / PyTorch / CUDA, 掌握数据结构、OS、计组、计网与数据库; 理解 Transformer 与 post-training · 并行计算 · KV Cache · GPU 资源调度 · 向量检索与 RAG · Agent Runtime。
- **科研能力**: 能够围绕具体问题开展论文检索和阅读, 方法拆解与方案设计, 从已有工作的局限中找寻问题、积累 idea 与 insight, 并通过实验迭代验证和改进方案; 具备英文论文阅读与写作能力。
- **工程能力**: 具有系统开发、架构设计与性能调优经验; 参与 GPU 向量检索、动态索引、batch 调度和显存管理优化, 独立完成 RAG / Agent 全链路系统。

🔗 AI Infra · Agent Systems · 具身智能

研究兴趣 · 未来方向

- **研究兴趣**: 聚焦 AI Infra、Agent Systems 并关注具身智能。AI Infra 方面, 关注大模型训练与推理效率、GPU 资源管理、在线推理与检索调度及高性能向量检索; Agent Systems 方面, 关注长时程自进化 Agent 中 Agentic Retrieval、长期记忆、任务规划的协同; 具身智能方面, 关注三维场景表示驱动的环境理解、决策与规划与 Sim2Real。希望为复杂智能体构建**高效、可靠、可扩展的系统基础设施**。
- **未来方向**: 计划以 AI / Agent Infra 为主要研究主线, 基于 GPU 向量检索、显存管理、batch 调度与 Agent 系统开发经验, 重点探索检索、记忆、推理与工具执行之间的系统协同, 以及长时程 Agent 任务中的**效率、扩展性与可靠性问题**。考虑继续深化三维视觉基础, 探索三维场景表示在智能体空间记忆、环境理解与决策规划中的作用, 并逐步拓展至 Sim2Real。**希望通过持续跟踪前沿、在具体问题中积累想法和方法, 保持与同行交流, 逐步形成独立提出问题、设计方法并实验迭代的科研能力, 并以攻读博士为长期规划。**