

重庆大学 / 计算机科学与技术  
本科在读 / 2023.09 - 2027.06  
GPA 3.64/4.00 · 排名 35/309  
均分 88.69 · 综测年级前 3% · TOEFL 110

个人主页 [/ xiaoweihua.cn](https://xiaoweihua.cn)  
Github [/ Will-hxw](https://github.com/Will-hxw)  
邮箱 [/ xiaoweihuacq@gmail.com](mailto:xiaoweihuacq@gmail.com)



## 实习经历

### Tencent 腾讯 · TRS 推荐中台 / 推荐系统基础架构中心

向量数据库实习生 2025.06 - 2025.08

C++ / CUDA / Python / Golang / Faiss

- overview** 参与面向推荐系统与 RAG 场景的 GPU 向量数据库优化，围绕 Faiss GPU 检索、实时向量增删改、GPU batch 调度与 CUDA VMM 显存管理提升大规模向量召回性能与在线稳定性。
- optimize** 针对 Faiss GPU 在大 top-k 检索场景下 selection 阶段吞吐下降的问题，参考 RadIK top-k selection 算法并适配分块距离计算流程，突破原有 top-k 限制；在 top-k=2048 场景下将 GPU 检索 QPS 提升约 13x，P99 延迟由秒级降至百毫秒级。
- feature** 参与 Faiss 实时向量增删改能力建设，基于 CUDA VMM 虚拟显存机制重映射 id，减少删除/更新过程中的大规模内存拷贝，将单条文档删除从毫秒级优化至微秒级，支撑推荐召回与 RAG 文档库的高频动态更新。
- infra** 参与 GPU 检索 batch 调度组件设计，基于无锁队列 + 专用 batch 线程 + 线程池执行模型，将线上零散单 query 请求自动聚合为大 batch，提升 GPU 利用率与系统 QPS。
- infra** 参与 CUDA VMM 显存管理优化，引入按需分页扩容与分块计算策略，支持同卡多索引实例稳定运行、降低显存扩容峰值导致的 OOM 风险；在百万级高维向量检索场景下，相较纯 CPU 方案实现单节点 QPS/cost 数量级提升。

## 科研训练

### 三维视觉与神经渲染科研训练：NeRF / 3D Gaussian Splatting

科研训练 2025.08 - 至今

文献阅读 · 复现 · 实验分析

- survey** 围绕三维视觉与神经渲染方向开展系统科研训练，精读 NeRF、Instant-NGP、Mip-NeRF、3D Gaussian Splatting、SuGaR、2DGS 等代表性工作，梳理隐式辐射场（NeRF 族）与显式高斯表示（3DGS 族）两条技术路线的设计动机、核心差异与适用场景，深入理解体渲染积分、球谐函数与可微光栅化在三维表示中的数学原理及计算效率差异。
- pipeline** 完成 COLMAP 相机位姿恢复 → 稀疏点云生成 → 数据预处理 → 3DGS 训练配置调参 → 新视角渲染可视化全流程复现，掌握从 SfM 稀疏重建到可微高斯渲染的完整管线；在多组真实场景上独立开展新视角合成实验，对比不同视角密度下渲染质量与训练收敛速度的差异曲线。
- experiment** 重点分析 3DGS 在稀疏视角、弱纹理与复杂边界区域下的漂浮伪影、纹理过拟合与几何不稳定性现象，系统对比输入视角数量（3-50 帧）对 PSNR / SSIM 指标的影响，记录 densification 阈值与 pruning 策略如何改变高斯数量分布和最终渲染质量，形成包含定量曲线与定性渲染对比的阶段实验报告。
- analysis** 围绕异常重建结果，分析相机位姿估计误差、视角覆盖均匀性与 initial points 质量对 3DGS 重建稳定性的影响，明确 COLMAP 前端在不同场景纹理丰富度下的失效模式；为后续稀疏视角高质量重建的改进方向提供实验依据。

## 项目经历

### Synthos-QQ · 聊天记录语义分析与 Agent 系统

GitHub [项目唯一负责人](#) 2026.02 - 至今

TypeScript / Node.js / React / bge-m3 / RAG / Agent / SSE

- design** 独立设计并开发面向 QQ 聊天记录的全链路分析系统，构建数据接入 → 清洗 → 语义向量化 → RAG 检索 → Agent 问答端到端流水线，将约 140 万条非结构化历史消息转化为可检索、可交互的个人知识流。
- feature** 基于 bge-m3 生成 1024 维语义向量，结合 RAG 机制召回相关上下文并由 LLM 生成带引用、可回溯到原始消息的回答；集成 WebUI Agent，支持 SSE 流式输出与工具调用，可按时间、群组或话题开展多轮问答。
- feature** 设计周期性摘要与日报生成流程，基于语义线索提取高频话题与关键事件；采用 pnpm monorepo 组织各模块，配合 MongoDB 任务调度。

### 🏆 学科竞赛与奖学金

算法 · 数学 · 综合

- 2025 年 ACM-ICPC 国际大学生程序设计竞赛 银牌
- 2026 年 团体程序设计天梯赛 个人三等奖
- 2025 年 百度之星程序设计大赛 银奖
- 2021 年 高中数学联赛 江西省一等奖
- 2023 年 全国大学生数学竞赛 重庆赛区一等奖
- 2025 年 国家励志奖学金
- 校级甲等奖学金 3 次 (综合评测年级前 3%)

## 技术能力与研究兴趣

### 🔧 技术能力

数学与Coding · 专业基础 · 科研基础 · 工程基础

- **数学与 Coding 基础**: 高中数学联赛江西省一等奖、全国大学生数学竞赛重庆赛区一等奖、ACM-ICPC 国际大学生程序设计竞赛银牌; 长期训练覆盖数学建模、复杂度分析与 C++ 算法实现, 具备面向机器学习与视觉计算的数学基础。
- **专业基础**: 熟悉 C++ / CUDA / Python / TypeScript, 课程与自学覆盖数据结构、操作系统、计算机组成、计算机网络、数据库、机器学习与深度学习; 对多视角几何、相机模型与三维重建基础有一定了解。
- **科研基础**: 围绕 NeRF/3DGS 精读代表性工作并完成 COLMAP-3DGS 完整复现流程, 理解隐式/显式三维表示与可微渲染方法; 重点关注不同输入条件下的重建质量、几何稳定性与模型泛化表现。
- **工程基础**: 在腾讯向量数据库实习中参与 Faiss GPU 检索、CUDA VMM 显存管理与 batch 调度优化, 积累 GPU 系统性能调优经验; 独立完成 Synthos-QQ 全链路语义检索与 Agent 分析系统。

### 🔬 研究兴趣与未来方向

深造规划 · AI Infra 与视觉智能

- **研究兴趣**: 围绕 AI Infra、三维视觉与具身智能三个相互关联的方向展开, 同时关注世界模型、多模态大语言模型等快速演进的前沿领域。AI Infra 方面延续 GPU 向量数据库与 CUDA 系统优化的实习积累, 关注大规模模型训练与推理的系统效率、显存管理与分布式调度。三维视觉方面基于 NeRF/3DGS 的科研训练, 关注神经渲染、稀疏视角重建与三维场景理解, 以及可微表示在机器人感知中的应用。具身智能与世界模型方面, 关注以三维场景表示为基座的机器人环境建模与空间推理, 以及世界模型在物理交互与长期规划中的角色。同时对 RAG 检索增强生成与 Agent 系统的工程落地保持持续关注。
- **未来方向**: 研究生阶段希望在 AI 系统与视觉智能的交叉地带逐步深入。初期以三维视觉与神经渲染为切入点, 在已有 COLMAP-3DGS 实验基础上系统学习多视角几何与可微渲染; 中长期通过持续阅读与实验积累, 在 AI Infra、三维视觉、具身智能或其交叉地带逐步聚焦到具体的研究问题上。作为刚接触科研的本科生, 希望从扎实的文献阅读与实验复现做起, 持续跟踪前沿、在具体问题中积累 insight, 保持与同行交流, 踏实推进有实际价值的工作。