

男 / 2005.08

个人主页 [⊕ / xiaoweihua.cn](https://xiaoweihua.cn) [↗](#)重庆大学 · 计算机学院 / 计算机科学与技术 [985](#) [211](#) [双一流](#)Github [🔗](#) / Will-hxw [↗](#)

本科在读 / 2023.09 - 2027.06

邮箱 [✉ / xiaoweihuacqu@gmail.com](mailto:xiaoweihuacqu@gmail.com) [✉](#)

GPA 3.64/4.00 · 排名 35/309 / 综测年级前 3% · TOEFL 110

实习经历

[Tencent 腾讯 · TRS 推荐中台 / 推荐系统基础架构中心](#)

[向量数据库实习生](#) [2025.06 - 2025.08](#)[C++](#) / [CUDA](#) / [Python](#) / [GoLang](#) / [Faiss](#)

- 参与面向推荐系统与 RAG 场景的 GPU 向量数据库优化, 围绕 Faiss GPU 检索、实时向量增删改、GPU batch 调度与 CUDA VMM 显存管理提升大规模向量召回性能与在线稳定性。
- 针对 Faiss GPU 在大 top-k 检索场景下 selection 阶段吞吐下降的问题, 参考 RadiK top-k selection 算法并适配分块距离计算流程, 突破原有 top-k 限制; 在 top-k=2048 场景下将 GPU 检索 QPS 提升约 13x, P99 延迟由秒级降至百毫秒级。
- 参与 Faiss 实时向量增删改能力建设, 基于 CUDA VMM 虚拟显存机制重映射 id, 减少删除/更新过程中的大规模内存拷贝, 将单条文档删除从毫秒级优化至微秒级, 支撑推荐召回与 RAG 文档库的高频动态更新。
- 参与 GPU 检索 batch 调度组件设计, 基于无锁队列 + 专用 batch 线程 + 线程池执行模型, 将线上零散单 query 请求自动聚合为大 batch, 提升 GPU 利用率与系统 QPS。
- 参与 CUDA VMM 显存管理优化, 引入按需分页扩容与分块计算策略, 支持同卡多索引实例稳定运行、降低显存扩容峰值导致的 OOM 风险; 在百万级高维向量检索场景下, 相较纯 CPU 方案实现单节点 QPS/cost 数量级提升。

科研训练

[三维视觉 / 神经渲染: NeRF 与 3D Gaussian Splatting](#)

[科研训练](#) [2025.08 - 至今](#)[文献阅读](#) · [复现](#) · [实验分析](#)

- 围绕三维视觉与神经渲染方向开展系统科研训练, 精读 NeRF、Instant-NGP、Mip-NeRF、3D Gaussian Splatting、SuGaR、2DGS 等代表性工作, 理解隐式辐射场、显式高斯表示、体渲染、可微光栅化与相机位姿估计之间的关系。
- 完成 COLMAP 相机位姿恢复 → 稀疏点云生成 → 数据预处理 → 3DGS 训练配置调参 → 新视角渲染可视化完整流程, 开展多视角重建与新视角合成实验复现。
- 重点分析 3DGS 在稀疏视角、弱纹理与复杂边界区域下的漂浮伪影、纹理过拟合与几何不稳定现象, 对比输入视角数量、训练迭代次数、densification 与 pruning 策略对重建质量的影响, 形成阶段性实验记录与技术报告。
- 围绕异常渲染结果进一步分析相机位姿质量、输入视角覆盖、densification / pruning 策略与重建质量之间的关系, 为后续稀疏视角高质量重建实验设计提供依据。

项目经历

[Synthos-QQ · 面向 QQ 聊天记录的语义信息处理与 Agent 分析系统](#)

[GitHub](#) [↗](#) [项目唯一负责人](#) [2026.02 - 至今](#)[TypeScript](#) / [Node.js](#) / [React](#) / [bge-m3](#) / [RAG](#)

- 作为项目唯一负责人, 设计并开发面向 QQ 聊天记录的全链路智能分析系统, 将本地即时通信记录从原始数据库读取 → 清洗 → 上下文拼接 → 语义向量化 → AI 摘要 → RAG 检索 → Agent 问答串联为完整数据处理链路, 把约 140 万条非结构化、口语化、强上下文依赖的历史消息转化为可检索、可总结、可交互的个人知识流。
- 实现 QQ 本地数据库聊天记录拉取与增量同步, 适配 Windows x86_64 与 macOS Apple Silicon 数据源; 面向 5 个群组设计 preprocessing 流程, 完成消息清洗、群组分组、上下文拼接与引用消息解析, 缓解碎片化、噪声多、上下文缺失问题。
- 基于 bge-m3 生成 1024 维语义向量构建自然语言语义搜索能力, 结合 RAG 机制召回相关历史上下文并由 LLM 生成带引用、可回溯到原始消息的回答; 集成 WebUI Agent, 支持 SSE 流式输出与工具调用, 可围绕某段时间、群组或话题对历史记录开展多轮问答。

- 设计周期性摘要与日报生成流程（半日 / 周 / 月报），基于正/负向关键词与语义线索实现兴趣度指数排序，提取高频话题、关键事件与讨论结论并支持邮件推送。
- 采用 **pnpm monorepo** 组织 data-provider、preprocessing、ai-model、orchestrator、webui-backend、webui-frontend 等模块，配合 MongoDB 任务调度与可视化配置面板提升可维护性。

竞赛获奖与荣誉

🏆 学科竞赛与奖学金

算法 · 数学 · 综合

- 2025 年 ICPC 四川省邀请赛 银牌（国家级）
- 2026 年 天梯赛 个人三等奖（国家级）
- 2025 年 百度之星 银奖（省市级）
- 2023 年 全国大学生数学竞赛 重庆赛区一等奖（省市级）
- 2022 年 高中数学联赛 江西省一等奖（省市级）
- 2025 年 国家励志奖学金（国家级）
- 校级甲等奖学金 3 次（校级，综合评测年级前 3%）

技术能力与研究兴趣

🔧 技术能力

数学底层 · 专业基础 · 工程能力 · 科研能力

- **数学与算法基础**：高中数学联赛江西省一等奖、全国大学生数学竞赛重庆赛区一等奖、ICPC 四川省邀请赛银牌；长期训练覆盖数学建模、复杂度分析与 C++ 算法实现。
- **系统与工程基础**：熟悉 C++ / CUDA / Python / TypeScript，课程与自学覆盖数据结构、操作系统、计算机组成、计算机网络、数据库、机器学习与深度学习。
- **性能优化经验**：在腾讯向量数据库实习中参与 Faiss GPU 检索、CUDA VMM 显存管理、实时增删改与 batch 调度优化，围绕 selection、显存拷贝、请求聚合等瓶颈开展 profiling 与实现改造。
- **科研训练基础**：围绕 NeRF/3DGS 阅读代表性工作并完成 COLMAP-3DGS 复现，重点关注稀疏视角、弱纹理和复杂边界场景下的几何不稳定、漂浮伪影与训练策略影响。

🔍 研究兴趣与未来方向

深造规划

- 研究兴趣：以 **AI 系统与智能计算基础设施** 为主线，关注智能检索与向量数据库、RAG 基础设施、三维视觉与神经渲染（NeRF/3DGS）、多模态理解与空间智能等方向。
- 未来方向：研究生阶段希望围绕大模型推理系统、向量数据库与 RAG 基础设施、稀疏视角三维视觉或具身智能方向深入，关注可通过系统指标、实验结果与真实数据验证的研究问题。