



重庆大学 / 计算机科学与技术 (卓越专业)

个人主页 [/ xiaowei.hua.cn](https://xiaowei.hua.cn)

本科在读 / 2023.09 - 2027.06

GitHub [/ Will-hxw](https://github.com/Will-hxw)

GPA 3.64/4.00 · 排名 35/309

邮箱 [/ xiaowei.huacqu@gmail.com](mailto:xiaowei.huacqu@gmail.com)

均分 88.69 · 综合测评年级前 3% · TOEFL 110

电话 / 微信 [/ 15730810078](https://t.me/15730810078)

实习经历

Tencent 腾讯 · TRS 推荐中台 / 推荐系统基础架构中心

向量数据库实习生 2025.06 - 2025.08

C++ / CUDA / Python / Faiss / CUDA VMM

overview

参与推荐召回与 RAG 检索场景下的 GPU 向量检索基础设施建设, 围绕大 top-k selection、在线向量增删改、batch 调度与 CUDA VMM, 优化大规模向量召回的吞吐、尾延迟和动态更新效率, 并降低同卡多索引部署的 OOM 风险。

optimize

针对 Faiss GPU 大 top-k 检索中 selection 开销显著上升、原有 selection 接口难以直接处理分块距离结果的问题, 借鉴 Radik 的 radix selection 方法, 重构分块距离计算与 top-k selection 的衔接流程; 在 top-k=2048 场景下将 GPU 检索 QPS 提升约 13x, P99 延迟由秒级降至百毫秒级。

realtime

参与 Faiss GPU 在线向量增删改功能开发, 引入 CUDA VMM 虚拟显存管理实现向量槽位与物理显存页的动态映射, 并结合哈希表维护文档 ID 到向量槽位的映射, 减少删除与更新触发的数据压实及批量显存搬移, 将单条文档删除延迟由毫秒级降至微秒级。

scheduling

参与 GPU 检索在线请求聚合与调度组件设计, 使用无锁队列接收高并发请求, 由专用 batch 线程聚合零散单-query 请求, 并分发至检索线程池执行, 在控制排队延迟的同时增大有效 batch size, 提高 GPU 利用率与系统吞吐。

memory

参与 CUDA VMM 显存管理优化, 通过虚拟地址预留与物理页按需映射减少索引扩容中的重分配及数据搬移, 并以分块距离计算控制检索临时显存, 支持同卡部署多个索引实例, 降低扩容及数据更新阶段的 OOM 风险。

科研经历

PAC-GS: 稀疏视角 3DGS 的跨视角审计与可回滚增密

科研经历 2025.08 - 至今

PyTorch / COLMAP / 3DGS / 可微渲染 可回滚增密 · 操作级跨视角审计 · 新视角合成

problem

原始 3DGS 的密度控制主要根据视空间位置梯度筛选增密对象, 并结合 Gaussian 尺度决定执行 clone 或 split。然而在稀疏视角条件下, 高梯度既可能源于真实结构欠表达, 也可能来自遮挡冲突、位姿误差或单视角过拟合, 使现有判据难以判断一次具体增密能否带来跨视角渲染收益。

idea

提出 PAC-GS (Probe-Audit-Commit) 可回滚密度控制框架, 将即时 clone / split 拆分为临时候选、短程适配、跨视角审计与条件提交四个阶段: 候选先在部分输入视角上进行短程适配, 随后在轮换审计视角上检查其是否仍能降低渲染损失; 通过审计的候选被提交至主模型, 其余候选直接撤销。

method

实现 候选适配、跨视角审计与操作级提交机制: 冻结主模型, 仅对临时候选进行短程优化, 并重分配父子不透明度以减少增密造成的渲染突变; 通过一阶梯度初筛与联合开关验证处理候选收益及遮挡交互, 最终在增长预算内提交有效操作。

result

在 LLFF 8 个场景的 3/6/9-view 稀疏视角实验中, 相较原始 3DGS 基线, PAC-GS 的 PSNR 平均提升 0.30 dB, 最终 Gaussian 数量平均减少 15%, 训练时间平均增加 18%, 在可控训练开销下改善了新视角渲染质量与模型紧凑性。

项目经历

面向即时通信消息的 Agentic Retrieval 系统

GitHub [独立开发](#) 2026.02 - 至今

Agent / RAG / BGE-M3 / TypeScript / MongoDB / React

problem

针对 IM 消息碎片化、表达口语化、话题交织及跨时段信息关联困难的问题, 构建 Agentic Retrieval 系统, 使用户围绕个性兴趣主题聚合有效信息、恢复事件上下文并追踪话题演化。

retrieval

设计查询规划—混合召回—相关性重排—上下文构建链路; 由 Agent 解析问题意图并生成时间、群组与话题约束, 基于 bge-m3 融合稠密与稀疏检索, 经 reranker 重排后按时间与话题聚合跨时段证据, 支持复杂约束查询与跨消息证据检索。

agent

将语义检索、结构化筛选、话题追踪和摘要生成封装为 Agent 工具, 引入证据充分性判定与 corrective retrieval; 在证据不足或冲突时自动改写查询并迭代检索, 生成附原始消息定位的回答总结。

system

设计消息—事件—主题三级知识组织与增量更新机制, 配合任务编排完成消息同步、向量索引更新和周期性事件与主题摘要合成, 实现跨时段问答、话题演化追踪及可追溯摘要生成。

🏆 学科竞赛与荣誉

算法 · 数学 · 综合

- 2025 年 ACM-ICPC 国际大学生程序设计竞赛 银牌
- 2026 年 团体程序设计天梯赛 个人三等奖
- 2025 年 百度之星程序设计大赛 银奖
- 2021 年 高中数学联赛 江西省一等奖
- 2023 年 全国大学生数学竞赛 重庆赛区一等奖
- 2025 年 国家励志奖学金
- 2026 年 重庆市创新能力优胜个人
- 校级甲等奖学金 3 次 (综合评测年级前 3%)

🔧 技术能力与研究兴趣

🔧 技术能力

数学与 Coding · 专业基础 · 科研能力 · 工程能力

- **数学与 Coding**: 具备手搓算法、复杂代码调试、论文公式推导与实验验证能力; 获 ICPC 银牌及高中数学联赛省一等奖。
- **专业基础**: 熟悉 C++ / Python / TypeScript / PyTorch / CUDA, 掌握数据结构、OS、计组、计网与数据库; 理解 Post-Training (SFT、DPO、RLHF、RLVR) · 并行计算与大模型推理系统 (KV Cache、Batching、GPU 资源调度) · 向量检索与 RAG · Agent Runtime。
- **科研能力**: 能够围绕具体问题开展论文检索和阅读, 方法拆解与方案设计, 从已有工作的局限中找寻问题、积累 idea 与 insight, 并通过实验迭代验证和改进方案; 具备英文论文阅读与写作能力。
- **工程能力**: 具有系统开发、架构设计与性能调优经验; 参与 GPU 向量检索、动态索引、batch 调度和显存管理优化, 独立完成 RAG / Agent 全链路系统。

🔗 LLM Reasoning & Post-Training · AI/Agent Infra · 智能检索

研究兴趣 · 未来方向 · 未来规划

- **研究兴趣**: 聚焦 LLM Reasoning & Post-Training、AI / Agent Infra 与智能检索。LLM Reasoning & Post-Training 方面, 关注基于 SFT、偏好优化与 RLHF / RLVR 的模型推理、工具使用与长时程任务能力提升; AI / Agent Infra 方面, 关注大模型训练与推理效率、GPU 显存与资源调度、KV Cache、batch 调度及 Agent Runtime; 智能检索方面, 关注高性能向量检索、混合召回与重排、Agentic Retrieval、长期记忆及检索—记忆—推理协同。希望围绕复杂智能体构建高效、可靠、可扩展的训练、推理与检索基础设施。
- **未来方向**: 计划以 AI / Agent Infra 为主要研究主线。AI Infra 方面, 希望结合 GPU 向量检索、显存管理与 batch 调度经验, 进一步研究大模型训练与推理中的 GPU 资源管理、显存与 KV Cache 管理、batching 与请求调度, 关注系统吞吐、延迟与资源利用率优化; Agent Infra 方面, 希望结合 Agent 系统开发经验, 探索长时程任务中检索、记忆、推理与工具执行的系统协同, 以及 Agent Runtime 中的状态管理、长期记忆与工具编排。同时进一步学习 LLM Reasoning & Post-Training, 关注偏好优化、RLHF / RLVR 等方法在推理能力、工具使用与多轮交互学习中的作用; 并持续深化高性能向量检索、混合召回与重排、Agentic Retrieval 等智能检索问题。
- **长期规划**: 希望扎实好基本功, 持续跟踪前沿、在具体问题中积累想法和方法, 保持与同行交流, 逐步形成独立提出问题、设计方法并实验迭代的科研能力, 并以攻读博士为长期规划。